

Automatsko prepoznavanje akorda iz audio zapisa

Definicija problema

Cilj projekta je da razvijem sistem koji može automatski da prepozna akorde u muzičkim snimcima. Ulaz u sistem je audio fajl (npr. .wav ili .mp3), a izlaz je niz akorda sa vremenskim oznakama kada se akordi menjaju. Problem posmatram kao sekvencijalnu klasifikaciju – model na osnovu audio signala klasifikuje trenutni akord (npr. C-dur, A-mol, G7, N).

Motivacija

Automatsko prepoznavanje akorda ima veliki značaj i praktične primene:

- **Obrazovanje:** pomaže muzičarima početnicima da uče sviranje prateći akorde u realnom vremenu.
- **Produkcija:** ubrzava kreiranje harmonijske osnove u muzičkoj produkciji.
- **Muzička pretraga i preporuke:** omogućava pretragu pesama po akordskim progresijama.
- **Transkripcija:** olakšava profesionalnim muzičarima i aranžerima brzo zapisivanje harmonije.

Rešenje ovakvog problema doprinosi razvoju muzičkih aplikacija i sistema za inteligentnu obradu zvuka.

Skup podataka

Za ovaj projekat koristim GuitarSet dataset <https://zenodo.org/records/3371780>

Opis GuitarSet-a:

- Sadrži 360 isečaka od po 30 sekundi.
- Snimljeno je na 6-kanalnim heksafonskim gitarama (poseban kanal za svaku žicu) + mikrofonski snimci.
- Svaki isečak ima precizne anotacije: note, akorde, taktove, downbeat-ove.
- Anotacije su dostupne u JAMS formatu (JSON za muzičke anotacije).
- Akordi su detaljno označeni (C:maj, A:min, G:7 itd.), što omogućava bogat vokabular.

Ciljno obeležje: akord u svakom vremenskom segmentu (frame ili beat).

Broj klasa: obuhvata sve standardne dur/mol akorde i ekstenzije (7, maj7, min7), uz posebnu oznaku „N“ (no chord).

Pretprocesiranje podataka

1. **Normalizacija audio signala:** resamplovanje na 44.1 kHz, mono ili čuvanje multi-kanala.
2. **Ekstrakcija fičra:** konstanto-Q hromagram (12 ili 24 binova po oktavi), HPCP ili melspektrogram.
3. **Beat-sinhronizacija:** grupisanje fičra po bitovima radi robusnijih predikcija.
4. **Augmentacija:** promena visine (± 2 semitona), time-stretch (± 5 –10%), dodavanje šuma.
5. **Poravnanje anotacija:** konverzija svih akorda u standardni vokabular.
6. **Podela podataka:** train/validation/test u odnosu 70/15/15, bez preklapanja izvođača

Metodologija

Ulaz: hrogram / spektrogram audio snimka.

Izlaz: vremenski poravnata sekvenca akorda.

Koraci:

1. Učitavanje i pretprocesiranje audio snimaka.

2. Ekstrakcija fičra (CQT, HPCP).

3. Treniranje modela:

- **Bazni model** (baseline): Hidden Markov Model (HMM) nad hrogramom.

- **Napredni model 1: CNN** (Convolutional Neural Network) - uči prostorne obrasce iz hrograma (tretira spektrogram kao sliku).

- **Napredni model 2: LSTM** (Long Short-Term Memory) - modeluje sekvencijalnu prirodu akorda, koristi informacije iz prošlosti za stabilnije predikcije.

- **Napredni model 3: CNN+LSTM hibrid** - CNN za ekstrakciju lokalnih obrazaca, LSTM za sekvencijalne zavisnosti.

- **Napredni model 4 (opciono): Transformer** - kao savremeni pristup sekvencijalnim podacima, sa pažnjom na dugoročnim relacijama između akorda.

Dijagram toka:

Audio → Pretprocesiranje → Ekstrakcija fičra → (CNN / LSTM / CNN+LSTM / Transformer) → Post-procesiranje (HMM/CRF) → Predikcija akorda

Evaluacija

Podela skupa: 70% train, 15% validation, 15% test.

Metrike:

Chord Symbol Recall (CSR): koliko puta je pogodjen pravi akord.

Weighted CSR (WCSR): tačnost ponderisana trajanjem akorda.

Overlap Ratio: procenat vremena kada su predikcija i istina isti.

Uporedna analiza: poređenje HMM-a (baseline) sa CNN, LSTM i Transformer pristupima.

Tehnologije

Python

PyTorch (CNN, LSTM, Transformer modeli)

librosa (obrada zvuka, ekstrakcija fičra)

mirdata (učitavanje GuitarSet dataseta)

scikit-learn (bazni modeli, metrike)

NumPy, Pandas, Matplotlib (analiza i vizuelizacija)

Relevantna literatura i resursi

GuitarSet dataset: <https://guitarset.weebly.com/>

Isophonics dataset: <https://isophonics.net/datasets>

McGill Billboard dataset: <https://www.kaggle.com/datasets/jacobvs/mcgill-billboard>